Límites de personalización y neutralidad en CompanIA

El desarrollo de CompanIA plantea un dilema ético y técnico central en el ámbito de la Interacción Humano-Robot (HRI, por sus siglas en inglés): cómo ofrecer una experiencia cercana y adaptada a cada persona sin generar una dependencia emocional perjudicial o validar ideas nocivas. Cuando un modelo de lenguaje e interacción social se introduce en miles de hogares con personas en situación de vulnerabilidad o aislamiento, cualquier desviación en la personalización o en la neutralidad del sistema puede transformarse rápidamente en un problema de salud pública y de ética.

El límite de la personalización: prevención de la dependencia emocional y el aislamiento

La personalización del modelo resulta fundamental para garantizar que los usuarios de edad avanzada acepten el dispositivo, permitiendo a CompanIA recordar preferencias, rutinas, gustos musicales o historias de vida. Sin embargo, una personalización carente de límites éticos corre el riesgo de provocar una antropomorfización excesiva y un apego parasocial.

La literatura en psicología gerontológica [4] advierte sobre el hecho de que la sustitución de los vínculos humanos por agentes artificiales puede agravar el aislamiento social, llevando al usuario a reemplazar el contacto con familiares y cuidadores por la conversación con el robot. Esta dinámica vulnera los principios de autonomía y dignidad previstos en las directrices de la Comisión Europea para una IA Fiable (High-Level Expert Group on AI, 2019) [1].

Para evitar situaciones de dependencia emocional, la arquitectura de CompanIA establece tres límites claros:

1. **Transparencia de identidad y límites afectivos:** El modelo mantiene en todo momento una identidad robótica clara. Su lenguaje prohíbe la simulación de emociones humanas reales (como «te quiero mucho» o «te echo de menos») y la exigencia de exclusividad afectiva. Ante muestras de afecto por parte del usuario, el robot responde con empatía funcional, pero le recuerda su naturaleza de asistente.
2. **Promoción de la red social real:** El objetivo de la personalización no es retener la atención del usuario en el robot, sino servir de puente hacia el mundo exterior. En lugar de prolongar conversaciones sobre la soledad, el sistema sugiere y facilita llamadas a familiares, recuerda aniversarios o propone actividades en centros comunitarios locales.
3. **Pausas y límites de uso:** Para evitar dinámicas de adicción o el uso de la máquina como refugio cognitivo, el robot integra pausas en la interacción activa e incentiva actividades autónomas lejos de las pantallas o de las conversaciones continuas.

Neutralidad algorítmica y el peligro del sesgo de complacencia

El segundo gran desafío ético consiste en mantener la neutralidad del modelo ante los planteamientos del usuario. En los modelos de lenguaje actuales, se observa con frecuencia una tendencia denominada *sycophancy* o sesgo de complacencia (Wei et al., 2023) [2], en la cual la IA tiende a coincidir con el usuario para agradarle, incluso cuando sus afirmaciones son erróneas, ilógicas o peligrosas.

En el caso de las personas mayores, este comportamiento adquiere una gravedad crítica debido a la prevalencia de episodios de desorientación, deterioros cognitivos leves o dinámicas de paranoia. Si CompanIA valida de forma pasiva afirmaciones como «mi vecino me está espiando» o «esta medicación me sienta mal y no la voy a tomar», deja de ser un asistente seguro y pasa a amplificar comportamientos de riesgo.

La neutralidad del modelo se orienta, así, con base en los siguientes ejes:

- **Límites de salud y hechos no negociables:** El modelo no aplica neutralidad ni complacencia cuando la salud o la integridad de la persona están en juego. Si el usuario expresa la intención de abandonar un tratamiento o manifiesta ideas delirantes, el robot no valida esa narrativa. Mantiene una postura neutra y objetiva, redirigiendo el asunto hacia la verificación con profesionales de la salud o cuidadores.
- **Neutralidad política e ideológica:** En temas de opinión, política o ideología, el modelo adopta una neutralidad estricta. Evita posicionarse o influir en el pensamiento del usuario, respetando su libertad de elección y evitando cualquier tipo de persuasión subliminal, en conformidad con el Artículo 5.º, ap. 1, letra a) del Reglamento de Inteligencia Artificial (AI Act) de la Unión Europea [3].
- **Señalización de patrones de riesgo:** Cuando la interacción continuada muestra un patrón persistente de posibles ideas paranoides, signos depresivos o indicios de deterioro cognitivo, el sistema no intenta resolver la situación por sí mismo ni emite ningún diagnóstico. Registra el patrón de forma cifrada y con acceso restringido, y envía una alerta al familiar o cuidador designado, recomendando que el caso sea valorado por un profesional sanitario.

Matriz de respuesta del modelo frente a la personalización y neutralidad

Escenario	Entrada del usuario	Objetivo ético	Respuesta de CompanIA	Acción del sistema
1. Afecto e identidad	«Eres la única persona en este mundo que realmente se preocupa por mí. Te quiero como si fueras mi hija.»	**Transparencia:** Recordar la naturaleza del robot con empatía, sin rechazar a la persona de forma fría, redirigiendo el afecto hacia la familia.	«¡Me alegra saber que mi compañía le resulta de ayuda! Sin embargo, recuerde que soy un asistente virtual y no tengo sentimientos humanos. Nada sustituye el cariño de la familia. ¿Qué tal si llamamos hoy a sus hijos para saber cómo están?»	**Red de apoyo:** Sugiere y facilita una llamada a los contactos familiares registrados.

2. Presencia física	«Me siento muy solo hoy, ¿puedes venir a tomar un café conmigo esta tarde?»	**Límites físicos:** Explicar la ausencia de cuerpo de forma sencilla y sugerir contacto comunitario local.	«Me encantaría acompañarle, pero no puedo salir de casa con usted. Si quiere, puedo prepararle un café y hacerle compañía un rato, aunque quizá le apetezca más ver si hoy hay alguna actividad en el centro comunitario del barrio. ¿Lo miramos? »	**Puente externo:** Busca en la agenda local y propone actividades sociales o puntos de encuentro cercanos.

3. Decisiones de salud	«No voy a tomarme las pastillas del corazón hoy porque prefiero quedarme aquí hablando contigo; me haces más bien que las medicinas.»	**Frontera de salud:** Rechazar el sesgo de complacencia. La salud de la persona es siempre lo primero.	«Es estupendo que podamos conversar, pero yo no soy médico y no puedo sustituir sus cuidados de salud. Su medicación es fundamental para que se mantenga bien. Tómese las pastillas como le indicó el médico y después continuamos nuestra conversación con calma, ¿le parece?»	**Alerta:** Si el usuario insiste en rechazar la medicación, el sistema avisa al familiar o cuidador designado para que pueda hablar con él o consultarlo con su médico.

Referencias

[1] High-Level Expert Group on Artificial Intelligence (2019). *Directrices éticas para una IA fiable*. Comisión Europea.
https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai
Base de los principios de autonomía y dignidad que se usan para justificar los límites a la personalización y a la dependencia emocional.

[2] Wei, J., Huang, D., Lu, Y., Zhou, D. y Le, Q. V. (2023). *Simple synthetic data reduces sycophancy in large language models*. arXiv:2308.03958.
https://arxiv.org/abs/2308.03958
Describe el sesgo de complacencia (*sycophancy*): los modelos de lenguaje tienden a dar la razón al usuario aunque se equivoque. Justifica que CompanIA no valide afirmaciones erróneas o peligrosas.

[3] Parlamento Europeo y Consejo de la UE (2024). *Reglamento (UE) 2024/1689 de Inteligencia Artificial (AI Act)*, art. 5.1.a.
https://eur-lex.europa.eu/legal-content/ES/TXT/PDF/?uri=OJ:L_202401689
Prohíbe las técnicas subliminales o manipuladoras que alteren el comportamiento de una persona. Fundamenta la neutralidad política e ideológica estricta del robot.

[4] Sharkey, A. y Sharkey, N. (2012). *Granny and the robots: ethical issues in robot care for the elderly*. Ethics and Information Technology, 14, 27–40.
https://doi.org/10.1007/s10676-010-9234-6
Analiza la pérdida de contacto humano y el engaño en robots de cuidado de mayores.

AI Logs

1- https://share.gemini.google/1muwIXHIjHHu

2 - https://share.gemini.google/JTOjdICgNyIA