Profundizar riesgos gran escala

En este documento vamos a profundizar más sobre los posibles riesgos de nuestro proyecto, en estos casos supondremos un uso muy alto de nuestro producto, causando que un pequeño fallo impacte a un gran número de personas. Debido a nuestro posibles clientes o usuarios sería prácticamente imposible llegar a cientos millones de usuarios, sin embargo, para este análisis supondremos que lo usan cientos de millones de personas.

Trade-off: Falsas alarmas vs Caídas no detectadas

Uno de los principales retos es equilibrar falsas alarmas y caídas no detectadas. No detectar una caída es especialmente grave en el público de CompanIA: según la OMS, las caídas causan unas 684 000 [1] muertes al año, son la segunda causa mundial de muerte por traumatismos involuntarios y afectan sobre todo a los mayores de 60 años. Para una persona mayor que vive sola, una caída no detectada puede suponer horas en el suelo sin ayuda.

Sin embargo, un sistema demasiado sensible traslada el problema a los servicios de emergencia, suponiendo un uso masivo sería un problema por si mismo. La función de detección de accidentes de Apple provocó, en un centro de emergencias de Colorado, 185 llamadas falsas en una sola semana de enero de 2023 [2], el doble de lo habitual. Además, este caso muestra que pedir confirmación al usuario no basta, ya que el dispositivo avisa antes de llamar y aun así los usuarios no respondían a tiempo. En personas mayores el problema se agrava, porque pueden no responder por sordera o deterioro cognitivo sin que haya una emergencia. A esa escala, aunque el detector acertara en el 99% de los casos, el 1% restante supondría cada año un número enorme de caídas sin atender o de llamadas innecesarias.

Por ello proponemos un protocolo escalonado:

1. El robot intenta comunicarse con la persona y comprobar visualmente su estado.
2. Si confirma que está bien, solo se registra el evento.
3. Si no responde o el caso es dudoso, se envía un informe a un centro de teleasistencia o a un cuidador, que decide si avisar a emergencias.
4. Solo ante alta certeza (impacto fuerte, inmovilidad prolongada) se llama directamente a emergencias.

Así, la decisión en los casos ambiguos recae en una persona y no en el algoritmo, y se reduce la carga sobre emergencias sin renunciar a la detección. Aun así, con cientos de millones de usuarios, el número de casos derivados a revisión humana sería muy alto. Por eso el umbral a partir del cual se deriva un caso se estudiará

junto con los centros de teleasistencia, ajustándose a su capacidad real, y su coste se tendrá en cuenta en el modelo de negocio.

Problemas de software

Otro problema es el del fallo correlacionado, también llamado monocultivo algorítmico (Kleinberg y Raghavan, 2021 [3]). Como todos los robots funcionan con el mismo modelo, Gemini Robotics, y reciben las mismas actualizaciones, si el modelo tiene un error, lo tienen todos los robots a la vez, y si una actualización sale mal, fallan todos al mismo tiempo.

Otro problema relacionado con el software son los sesgos sistemáticos de nuestros modelos de voz y visión. En un solo robot un sesgo parece un error puntual, pero a gran escala significa que colectivos enteros reciben peor atención de forma permanente: personas con acentos marcados, con dificultades del habla como la disartria, hablantes de lenguas cooficiales como el catalán, el gallego o el euskera, o personas de piel oscura en el caso de la visión. No es un riesgo teórico. Koenecke et al. (2020) [4] comprobaron que los sistemas comerciales de reconocimiento de voz casi duplicaban la tasa de error con hablantes negros respecto a hablantes blancos, y Buolamwini y Gebru (2018)[5] encontraron que los sistemas de análisis facial fallaban mucho más con mujeres de piel oscura que con hombres de piel clara. Para reducirlo, el modelo debe entrenarse con datos variados que le permitan generalizar bien, con la posibilidad de hacer un pequeño fine-tuning posterior para casos concretos. Además, antes de lanzarlo se medirá su rendimiento por separado para cada grupo, y si con alguno no alcanza un mínimo aceptable, no se desplegará para ese uso hasta corregirlo (se pondrá atención en realizarlo lo antes posibles para evitar “injusticias”).

Lo mismo ocurre con los accidentes que pueda causar el propio robot. Podemos conseguir una tasa de incidentes muy baja por hora de uso, pero multiplicada por millones de hogares y miles de horas al año, el resultado sería un número considerable de golpes, empujones o caídas provocadas por el robot. Para reducirlo, el robot usará sensores para detectar a las personas a su alrededor y se moverá despacio en la mayoría de situaciones, aunque es un riesgo que nunca se podrá llevar a cero. Por eso el diseño debe seguir la normativa específica: el Reglamento (UE) 2023/1230 de Máquinas [6], aplicable desde enero de 2027 y que sustituye a la antigua Directiva de Máquinas, y la norma ISO 13482:2014 [7], que fija los requisitos de seguridad para robots de cuidado personal. En situaciones complejas y puntuales, el robot podrá pedir asistencia a un operador remoto, pero si no la recibe a tiempo pasará a un modo seguro en el que se detiene.

Posibles abusos o uso indebido

El principal riesgo, que ya identificamos en el sprint anterior, es el uso indebido de la cámara y de los datos del robot para controlar a la persona mayor o dependiente dentro de su propio entorno familiar. Que un familiar pueda ver en cualquier momento qué está haciendo su padre o revisar sus rutinas puede convertir una herramienta de ayuda en una forma de vigilancia. Para evitarlo, el acceso a esta información estará sujeto a unas reglas estrictas y personalizadas, que fijarán quién puede acceder, a qué datos y en qué situaciones. Estas reglas se acordarán entre el usuario y sus familiares, pero en caso de desacuerdo prevalecerá siempre lo que decida el usuario principal. La única excepción será cuando exista una medida de apoyo reconocida legalmente que permita a un familiar decidir en nombre de la persona. En ese caso, el familiar podrá ampliar el acceso solo dentro de lo que dicha medida le permita. Por otro lado, para resolver el problema del consentimiento que planteamos en el sprint anterior como posible riesgo, hemos decidido que CompanIA no esté dirigido a personas con un deterioro cognitivo grave, como un Alzheimer avanzado o enfermedades similares. En esos casos, recomendaremos siempre un cuidador humano.

Para anticipar los usos abusivos, el sistema no se limitará a registrar los accesos, sino que los hará visibles. Cada vez que alguien acceda a la cámara, el robot lo indicará con una luz y un aviso de voz, de forma que la persona nunca sea observada sin saberlo. El usuario podrá consultar en cualquier momento quién ha accedido, cuándo y a qué. Por defecto, los familiares solo recibirán alertas ante situaciones de riesgo, como caídas o cambios bruscos de rutina, y no tendrán acceso libre a la cámara en directo. Además, el sistema detectará patrones sospechosos, como accesos muy frecuentes o a horas poco habituales. Cuando los detecte, preguntará al usuario en privado si está de acuerdo con ese nivel de supervisión.

Este problema cobra mucha más importancia si pensamos en un despliegue a gran escala. Si CompanIA llegara a cientos de millones de hogares, bastaría con que un 1% de las familias hiciera un uso controlador para que millones de personas mayores vivieran vigiladas en su propia casa. A esa escala, el riesgo ya no es solo individual. Podría normalizarse la idea de que las personas mayores deben estar supervisadas constantemente, lo que perjudicaría precisamente al colectivo al que el robot pretende ayudar. Por eso, estas protecciones no pueden ser opcionales, sino que deben venir activadas por defecto en todos los robots.

Posibles problemas de seguridad

En el apartado anterior el riesgo venía del propio entorno familiar. Pero un robot con cámaras, micrófonos y brazos dentro de cientos de millones de hogares también es un objetivo muy atractivo para terceros que quieran causar daño a propósito.

Agrupamos aquí tres riesgos con un origen común: que alguien ajeno al usuario consiga controlar el robot, ver lo que ve o hablar a través de él.

El primero es el secuestro de la flota. Ya existen precedentes con dispositivos mucho más simples. En 2024 unos atacantes tomaron el control de robots aspiradores Ecovacs en varias ciudades de EE. UU. y los usaron para insultar a sus dueños por el altavoz [8]. En 2025, un análisis de seguridad del humanoide Unitree G1 descubrió que enviaba telemetría a servidores externos sin que el usuario lo supiera [9]. En 2016, la botnet Mirai infectó cientos de miles de dispositivos IoT mal protegidos y los usó para dejar inaccesible parte de internet [10]. En nuestro caso el daño no se limitaría a los datos. Un robot con capacidad física podría convertirse en un peligro directo para la persona a la que cuida. Además, por el monocultivo algorítmico que explicamos antes, una sola vulnerabilidad en el software común afectaría a todos los robots a la vez.

El segundo son las fugas a través de los datos de entrenamiento y la teleoperación. Este riesgo nos afecta directamente, porque en el anexo de Componentes de IA y Datos indicamos que usaremos datos del uso del robot para mejorar el sistema, y en este mismo documento contemplamos un operador remoto para situaciones complejas. En 2022 se filtraron en redes sociales imágenes captadas por Roombas de desarrollo, entre ellas una mujer sentada en el váter. Las habían etiquetado trabajadores subcontratados en otro país [11]. Por otro lado, 1X (nombrado en el anexo de proyectos similares) reconoció en el lanzamiento de NEO, en octubre de 2025, que teleoperadores humanos pueden controlar el robot y ver el interior de la casa cuando la IA no sabe resolver una tarea [12]. Cada persona que ve o etiqueta estos datos es un punto de fuga posible.

El tercero es la manipulación comercial y el fraude. Una voz en la que la persona confía, dentro de su propia casa, podría usarse para empujarla a hacer compras, contratar suscripciones o cambiar de opinión. También podría ser suplantada: un estafador que se haga pasar por el robot o por el "soporte técnico de CompanIA" tendría mucha credibilidad. Las personas mayores ya son el principal blanco de este tipo de fraude, y según el FBI son el grupo con más pérdidas económicas por estafas [13]. Usar el robot de esta forma iría además contra el art. 5.1.b del AI Act, que prohíbe explotar vulnerabilidades por edad o discapacidad.

Nuestra postura: la ciberseguridad como prioridad de diseño

Suponemos que en 2030 las técnicas de protección estarán más maduras que hoy, pero eso no nos exime de tratar la seguridad como uno de los puntos claves del proyecto. Para nosotros es una prioridad por encima de añadir funciones, y si una función no se puede proteger adecuadamente, no se incluirá. Las medidas principales son:

1. Procesamiento local por defecto. Los modelos funcionan dentro del robot (como Gemini Robotics On-Device, ya citado en el anexo), de modo que imágenes y audio no salen de casa salvo en las situaciones previstas. Sin conexión, el robot sigue funcionando.
2. Actualizaciones firmadas y escalonadas. Solo se instala software verificado criptográficamente, y cada actualización se despliega primero en un grupo pequeño de robots antes de llegar al resto. Esto también reduce el riesgo del monocultivo.
3. Controles físicos que no dependen del software. Tapa física para la cámara y botón de parada que corta el movimiento, de forma que ni un atacante remoto puede anularlos. Es decir se podría tapar la cámara manualmente siempre que se quiera. Obviamente, si el usuario tapa la cámara es su responsabilidad de que el robot no pueda realizar tareas ni moverse. Mientras la cámara esté tapada, el robot seguirá detectando caídas con el resto de sensores, pero con menor fiabilidad, y se lo recordará al usuario cada cierto tiempo.
4. Teleoperación con las mismas reglas que el acceso familiar. El operador remoto solo actúa con permiso del usuario (puede haber sido dado previamente no en el momento), con la luz y el aviso de voz activados, y cada sesión queda registrada y visible para el usuario.
5. Datos de entrenamiento solo con consentimiento expreso. Antes de salir del robot, se descartan automáticamente las escenas íntimas (baño, desnudez) y se difuminan las caras, que no son necesarias para tareas como detectar caídas o manipular objetos. Cuando basta con la postura, se envía solo el esqueleto de la persona (puntos de articulaciones) en lugar del vídeo. El etiquetado lo hace personal propio dentro de la UE, nunca subcontratado fuera de ella.
6. Sin fines comerciales. El robot no muestra publicidad ni recomienda productos, y nunca puede realizar pagos ni pedir contraseñas o datos bancarios. Así el usuario sabe que cualquier petición de ese tipo es un intento de fraude, y el robot puede avisarle de ello.
7. Pruebas de ataque continuas. Auditorías externas, pruebas de penetración periódicas y un programa de recompensas para quien encuentre vulnerabilidades.

Estas medidas también responden a obligaciones legales. El Cyber Resilience Act (Reglamento (UE) 2024/2847), plenamente aplicable desde diciembre de 2027, exige que cualquier producto conectado se diseñe seguro desde el inicio y reciba parches durante su vida útil [14]. El art. 15 del AI Act pide a los sistemas de alto riesgo resistencia frente a ataques [15], y el Reglamento de Máquinas [6] incluye la protección frente a manipulaciones del software que afecten a la seguridad física. Aun así, ningún sistema es invulnerable. Por eso el objetivo no es solo evitar los ataques, sino que, si alguno tiene éxito, su alcance sea limitado y el usuario pueda detectarlo

Impacto social y dependencia del robot

A gran escala, CompanIA no solo afecta a cada hogar por separado, también a cómo se organiza el cuidado en general. Administraciones y aseguradoras podrían sustituir horas de ayuda a domicilio por robots porque sale más barato. Eso crearía un cuidado de dos niveles, en el que el trato humano sería un lujo y el robot quedaría para quien no puede pagar otra cosa. Además, no está claro que el robot reduzca el trabajo de los cuidadores. Wright estudió residencias japonesas con robots de cuidado y vio que muchas veces daban más trabajo al personal, no menos [16]. Por eso CompanIA debe presentarse siempre como un apoyo al cuidador y no como un sustituto de la atención humana. Algo parecido puede ocurrir dentro de las familias. Como ya señalamos en el sprint anterior y se remarcó en el debate, si el robot ya hace compañía, los familiares pueden sentir que no hace falta visitar tanto a la persona. A gran escala, esto podría normalizar que las personas mayores pasen más tiempo solas con una máquina, justo lo contrario de lo que busca CompanIA. Por eso el robot fomentará el contacto con familiares y amigos, por ejemplo recordando llamadas o facilitando videollamadas, en lugar de presentarse como su única compañía.

También existe el riesgo de depender de una sola empresa. Si millones de personas dependen del robot, un cierre o un cambio de política de CompanIA les deja sin ayuda de un día para otro. Ya ha pasado: en diciembre de 2024 cerró Embodied y sus robots Moxie, pensados para niños, dejaron de funcionar, aunque muchos niños estaban muy apegados a ellos [17]. Con los datos ocurre algo parecido. 23andMe sufrió en 2023 una brecha que afectó a unos 6,9 millones de usuarios y en 2025 entró en bancarrota, con sus datos genéticos como uno de sus principales activos [18]. Gracias al procesamiento local que explicamos en el apartado anterior, las funciones básicas de seguridad seguirían funcionando aunque la empresa desapareciera. Además, los contratos deben garantizar que los datos se borran si CompanIA cierra o se vende, en lugar de pasar al comprador.

Otro riesgo es el sesgo de automatización: cuando un sistema acierta casi siempre, las personas dejan de comprobarlo [19]. Si el robot detecta bien la gran mayoría de caídas, familias y cuidadores dejarán de estar pendientes y los pocos fallos pasarán desapercibidos. Esto es justo lo contrario de la supervisión humana que exige el AI Act. Por eso el robot no se presentará como infalible. Avisará también cuando tenga dudas, y el cuidador recibirá cada cierto tiempo un resumen de lo que ha detectado.

Por último, hay que tener en cuenta el coste ambiental. Millones de robots con baterías y tierras raras que habrá que renovar cada pocos años generan mucha basura electrónica. Solo en 2022 se produjeron 62 millones de toneladas de residuos electrónicos y se recicló correctamente alrededor de un 22% [20]. Un diseño modular, con baterías y piezas reemplazables, ayudaría a alargar la vida útil del robot.

Actores beneficiados y perjudicados

A esta escala, beneficios y perjuicios no se reparten por igual. Los principales beneficiados serían las personas mayores que viven solas y no pueden pagar un cuidador, que ganarían detección de caídas y ayuda en el día a día, y sus familias y cuidadores informales, que verían reducida parte de la carga de cuidado. También saldrían ganando las administraciones y aseguradoras, por el ahorro en ayuda a domicilio, y los proveedores tecnológicos como Google DeepMind, cuyo modelo y tecnología estaría en cientos de millones de hogares y reforzaría su posición dominante.

Los perjuicios, en cambio, recaen sobre colectivos concretos. Las personas con acentos marcados, disartria o que hablan lenguas cooficiales recibirían peor atención de forma sistemática. Las personas con menos recursos podrían quedarse con el robot como única opción de cuidado. Y los usuarios cuya familia haga un uso controlador del sistema vivirían vigilados en su propia casa. Fuera de los hogares, los profesionales de ayuda a domicilio podrían ver recortadas sus plantillas o, como en el caso japonés, aumentada su carga de trabajo, y los servicios de emergencia asumirían el coste de las falsas alarmas. Algunos actores aparecen en ambos lados. Las familias ganan tranquilidad, pero pueden caer en el sesgo de automatización. Las administraciones ahorran costes, pero se arriesgan a crear un cuidado de dos niveles. Por eso las medidas que proponemos se centran sobre todo en proteger a los colectivos perjudicados, que son los que más pierden si el sistema falla a gran escala.

Referencias

[1] - Organización Mundial de la Salud. (26 de abril de 2021). Página que habla sobre el problema de las caídas en personas mayores y consejos.
https://www.who.int/es/news-room/fact-sheets/detail/falls
[2] - Noticia sobre como la detección de caídas en apple watch estaba causando llamadas masivas a los servicios de emergencia (2023).
Apple Crash Detection Is Overwhelming Ski Town 911 Centers
[3] - Kleinberg, J. y Raghavan, M. (2021). Algorithmic monoculture and social welfare. Este artículo trata como con el incremento de uso de aplicaciones y software para la mayoría de cosas como fallos en estos se vuelven más cruciales y aumenta su impacto
-https://doi.org/10.1073/pnas.2018340118
[4] - Koenecke, A. et al. (2020). Racial disparities in automated speech recognition. Racial disparities in automated speech recognition | PNAS
[5] - Buolamwini, J. y Gebru, T. (2018). Gender shades: Intersectional accuracy disparities in commercial gender classification -
Buolamwini, J., & Gebru, T. (2018). Gender Shades Intersectional Accuracy Disparities in Commercial Gender Classification. Proceedings of Machine Learning Research, 81, 77-91. - References
[6] - Reglamento (UE) 2023/1230 del Parlamento Europeo y del Consejo, de 14 de junio de 2023, relativo a las máquinas. - Básicamente establece que se debe pasar un control por un organismo externo, pruebas de comportamiento y contacto con personas, ciberseguridad etc.- https://eur-lex.europa.eu/eli/reg/2023/1230/oj?locale=es
[7] - ISO. (2014). *ISO 13482:2014* Robots and robotic devices — Safety requirements for personal care robots.- Similar al anterior, controles para controlar la fuerza máxima, velocidad etc. - https://www.iso.org/standard/53820.html

[8] ABC News (octubre 2024).Hackers take control of robot vacuums in multiple cities, yell racial slurs. *Hackers take control of robot vacuums in multiple cities, yell racial slurs - ABC News*

[9] Alias Robotics (2025). Análisis de seguridad del humanoide Unitree G1, arXiv. Evidencia que un humanoide comercial ya envía datos a servidores externos sin conocimiento del usuario. *Cybersecurity AI: Humanoid Robots as Attack Vectors*

[10] Antonakakis, M. et al. (2017). Understanding the Mirai Botnet. USENIX Security Symposium. Ejemplo de cómo dispositivos domésticos inseguros, a gran escala, se convierten en un arma conjunta.
https://www.usenix.org/conference/usenixsecurity17/technical-sessions/presentation/antonakakis

[11] Guo, E. (2022). A Roomba recorded a woman on the toilet. How did screenshots end up on Facebook? MIT Technology Review. Muestra el riesgo de la revisión humana de datos de entrenamiento captados en el hogar.

A Roomba recorded a woman on the toilet. How did screenshots end up on Facebook? | MIT Technology Review

[12] Cobertura del lanzamiento de 1X NEO (octubre 2025). Precedente de teleoperación humana con acceso visual al hogar. *Así es Neo, el primer robot humanoide que llega al mercado prometiendo autonomía total | WIRED*

[13] FBI Internet Crime Complaint Center (2025). Elder Fraud Report 2024. Datos sobre las personas mayores como principal víctima del fraude. https://www.ic3.gov

[14] Reglamento (UE) 2024/2847 (Cyber Resilience Act). Requisitos de ciberseguridad obligatorios para productos con elementos digitales. https://eur-lex.europa.eu/eli/reg/2024/2847/oj

[15] Reglamento (UE) 2024/1689 (AI Act), art. 15. Exigencia de precisión, solidez y ciberseguridad en sistemas de IA de alto riesgo. https://eur-lex.europa.eu/eli/reg/2024/1689/oj

[16] Wright, J. (2023). *Robots Won't Save Japan: An Ethnography of Eldercare Automation*. Cornell University Press. Muestra que los robots de cuidado en Japón a menudo aumentaron la carga del personal en lugar de reducirla. https://www.jstor.org/stable/10.7591/j.ctv2fjx0br

[17] Cobertura del cierre de Embodied/Moxie (diciembre 2024). Precedente de robots que dejan de funcionar cuando la empresa cierra, con usuarios apegados a ellos.

https://www.axios.com/2024/12/10/moxie-kids-robot-shuts-down

[18] Cobertura de la brecha (2023) y la bancarrota (2025) de 23andMe. Precedente de datos muy sensibles convertidos en activo de venta tras la quiebra de una empresa.

23andMe will pay $18M to settle claims over massive data breach | Cybernews

[19] Parasuraman, R. y Manzey, D. (2010). Complacency and bias in human use of automation. Explica por qué las personas dejan de vigilar los sistemas automáticos fiables. https://doi.org/10.1177/0018720810376055

[20] UNITAR/ (2024). *Global E-waste Monitor 2024*. Datos sobre la generación y el reciclaje de residuos electrónicos a nivel mundial. https://ewastemonitor.info/

AI Logs

https://claude.ai/share/60239d95-8fec-491d-a37a-cbefb860324a - Uso de IA para sacar ideas y todos los puntos que deberíamos tratar en este apartado
https://claude.ai/share/24de0470-5ab5-4e2f-88a2-c15b49412426 - Inicialmente quería mejorar la redacción y termine corrigiendo ciertas frases e información
https://claude.ai/share/957d77e4-a2b2-4478-a12c-566fa782d080 -Sobre tema de ciberseguridad, en este caso si que utilice en gran parte su redacción ya que es un tema del cual no sabemos tanto y considero que es clave en el proyecto y debe quedar perfecto. Sin embargo corregí ciertas partes que chirriaban y le sugerí o pregunte sobre cosas. Las referencias fueron verificadas y leídas para comprobar que eran acordes.

https://claude.ai/share/4c553dc0-4635-4b68-a3f5-a87f5adeb663 - Colaboración con ideas y fuentes/noticias para respaldar los problemas sociales