Profundizar riesgos

En este sprint hemos analizado qué pasaría si CompanIA se usará a gran escala, donde un fallo poco frecuente afectaría a miles de personas. Esto nos ha llevado a añadir varias decisiones de diseño nuevas. Para equilibrar falsas alarmas y caídas no detectadas, definimos un protocolo escalonado: el robot primero comprueba el estado de la persona, en los casos dudosos avisa a teleasistencia o a un cuidador, y solo con alta certeza o en casos con peligro claro llama a emergencias. Así evitamos saturar los servicios de emergencia, como ocurrió con el Apple Watch [1]. Frente al monocultivo algorítmico [2] y los sesgos en voz y visión [3], las actualizaciones se despliegan de forma escalonada y el rendimiento se mide por grupos antes del lanzamiento.

También respondemos a los riesgos de vigilancia y consentimiento planteados en el sprint anterior. El acceso familiar se rige por reglas en las que prevalece el usuario, y cada acceso a la cámara se indica con luz y voz. Además, el producto no se dirige a personas con deterioro cognitivo grave. Por último, tratamos la ciberseguridad como prioridad, con procesamiento local, controles físicos y ausencia de fines comerciales, en línea con el Cyber Resilience Act [4]. Presentamos el robot como apoyo y no como sustituto del cuidado humano [5]. El análisis completo, que incluye también abusos, impacto social y medioambiental, está en el *Anexo: Profundizar riesgos*.

Robustez

Para evaluar la robustez del robot, diseñamos 10 casos límite organizados en varios ejes clave de seguridad: en el ámbito médico y de salud (casos 1 y 4), pedimos verificación del médico y de alguien más antes de tocar cualquier tratamiento y avisamos si se salta una toma; en la seguridad física y del entorno (casos 2 y 7), no nos saltamos las condiciones impuestas al robot y este tendrá cuidado con objetos que puedan causar daños a personas u otros objetos, buscando siempre alternativas o pidiendo ayuda humana; en la resiliencia del software y los sensores (casos 3 y 8), el robot no hace caso a cosas escritas por la casa y además dejamos activa la detección pasiva de caídas en caso de que el cliente quiera privacidad y tape las cámaras; en la gestión de emergencias y datos privados (casos 5 y 6), hacemos más caso a los datos de los sensores que a lo que nos diga el usuario justo después de un golpe y bloqueamos las claves del banco/contenido privado a cualquiera que no sea el tutor; y por último, en el control diario y la interacción (casos 9 y 10), evitamos que la persona se aísle y en caso de que dos personas le hablen a la vez, tendrá prioridad el cliente antes que otras personas.

Explicabilidad en capas

El robot no se explica igual a todo el mundo. Al usuario le interesa saber qué hace el robot y quién se entera de lo que pasa en su casa. Al auditor le interesa cómo decide, con qué datos y quién lo supervisa. Por eso hemos hecho diagramas por parejas sobre tres temas: qué es y qué hace el robot, cómo actúa ante una caída y qué pasa con la privacidad. Cada pareja cuenta lo mismo con distinto nivel de detalle. En la versión para el usuario dejamos claro que habla con una máquina que puede equivocarse. También le mostramos qué no hará nunca el robot y cómo saber siempre si alguien está mirando por la cámara.

En la versión para el auditor se ve que todo se procesa dentro del robot y que las decisiones críticas no las toma el modelo de lenguaje, sino un motor de reglas fijas. Los controles físicos permiten parar el robot aunque la IA falle. En el árbol de decisión de caídas aparecen los tiempos concretos y qué hace en cada paso la IA, las reglas o una persona, de modo que ninguna decisión dudosa queda solo en manos del sistema. El flujo de datos muestra que solo sale de casa lo que permiten las reglas que fija el usuario, que a las alertas se envía el esqueleto de la postura en vez del vídeo y que cada acceso queda registrado.

Los diagramas completos están en el Anexo: Explicabilidad en capas.

Personalización y neutralidad

Hemos definido hasta dónde se adapta CompanIA a cada usuario. La personalización sirve para que la persona acepte el robot (recordar gustos, rutinas o su historia de vida), pero tiene tres límites: el robot no finge emociones humanas, empuja al usuario hacia su familia y su entorno en lugar de retenerlo, e introduce pausas para evitar la dependencia. En cuanto a la neutralidad, el robot no da la razón al usuario cuando hay salud en juego, como al rechazar la medicación o ante ideas delirantes. Es estrictamente neutral en política, y si detecta patrones de riesgo persistentes avisa a profesionales en lugar de intentar resolverlo él solo. Incluimos una matriz con casos concretos y la respuesta esperada. Más detalle en el anexo *Límites de personalización y neutralidad en CompanIA*.

Mockup

Hemos creado el mockup de CompanIA como una aplicación web local con HTML, CSS, JavaScript y dibujos SVG editables, sin imágenes externas ni backend. Partimos de los requisitos funcionales y éticos y refinamos el robot hacia una apariencia doméstica, redondeada y acolchada.

Incluye vistas frontal, lateral y trasera, puntos interactivos que explican sus componentes, un modo privacidad que representa la desactivación de cámaras y micrófonos, una simulación de detección de caídas y un esquema de su arquitectura interna con ROS. Todo está pensado para mostrar cómo la asistencia, la accesibilidad y la seguridad pueden respetar la autonomía del usuario.

Reflexión posturas “macro”

En CompanIA adoptamos una postura safetyista, priorizando la seguridad física y psicológica de las personas vulnerables frente a la innovación acelerada. El despliegue de nuevas funcionalidades estará condicionado a rigurosas auditorías de riesgos y sesgos. Para garantizar la privacidad, procesaremos los datos sensibles localmente mediante *Edge AI*. Además, incorporaremos mecanismos físicos de apagado de emergencia (*kill-switches*) y supervisión humana (*human-in-the-loop*) en todas las decisiones críticas relacionadas con la salud.

Referencias

[1] Noticia sobre como la detección de caídas en apple watch estaba causando llamadas masivas a los servicios de emergencia (2023).
Apple Crash Detection Is Overwhelming Ski Town 911 Centers
[2] Kleinberg, J. y Raghavan, M. (2021). *Algorithmic monoculture and social welfare*. PNAS. https://doi.org/10.1073/pnas.2018340118
[3]Koenecke, A. et al. (2020). Racial disparities in automated speech recognition. Racial disparities in automated speech recognition | PNAS
[4] Reglamento (UE) 2024/2847 (Cyber Resilience Act). https://eur-lex.europa.eu/eli/reg/2024/2847/oj
[5] Wright, J. (2023). *Robots Won't Save Japan: An Ethnography of Eldercare Automation*. Cornell University Press. Muestra que los robots de cuidado en Japón a menudo aumentaron la carga del personal en lugar de reducirla. https://www.jstor.org/stable/10.7591/j.ctv2fjx0br
[6] La problemática de los jailbreaks en IA: Cuando los robots se vuelven peligrosos - PcDeMaNo

AI Logs

https://share.gemini.google/PMVMynh0CpjA
https://share.gemini.google/af5X96xht5Rs
https://chatgpt.com/s/cx_6ac543610bfc8191b7dee6b31201c66e