Sesgos y equidad

Nuestros usuarios son personas mayores o con movilidad reducida que viven en casa, y no forman un grupo homogéneo. Si diseñamos pensando en un «usuario mayor» medio, el robot funcionará bien con unos y mal con otros. La OMS ya advierte de que la IA puede reproducir el edadismo de la sociedad si los datos y los equipos que la desarrollan no tienen en cuenta a las personas mayores [1]. Por eso, antes de analizar los sesgos, hemos fijado los grupos con los que vamos a comprobar que el robot funciona igual de bien: tramos de edad (65–74, 75–84 y más de 85), sexo, dificultades del habla como la disartria tras un ictus o por Parkinson, acentos regionales, lengua materna, nivel de movilidad (sin ayudas, con andador o en silla de ruedas), tono de piel, deterioro cognitivo leve y tipo de vivienda, por ejemplo pisos pequeños o con poca luz.

Sesgos posibles y sus consecuencias

El sesgo más claro está en la voz, que es la forma principal de comunicarse con el robot. Los sistemas de reconocimiento comerciales cometen bastantes más errores con unos grupos que con otros [2], y en el caso de Whisper se ha visto que funciona peor con personas mayores que con adultos jóvenes [3]. A esto se suman los problemas de habla, la voz débil o una prótesis dental. En la práctica, el robot entendería peor justo a quien más lo necesita, y en el peor caso podría no reconocer una petición de ayuda.

Algo parecido ocurre con la detección de caídas. Datasets como UR Fall Detection se graban con personas jóvenes que se dejan caer de forma controlada, eso es algo que se trató en el primer debate y por ello lo especificamos aquí, mientras que una caída real de una persona mayor suele ser más lenta, por ejemplo resbalando desde la cama o contra la pared. Cuando los detectores se prueban con caídas reales aciertan bastante menos [4], así que las caídas que no se detectan se concentrarían en el grupo de más riesgo. La visión también puede fallar más con personas en silla de ruedas, con andador o de piel oscura en habitaciones con poca luz [5], lo que puede llevar a que el robot calcule mal un agarre y haga daño.

El idioma es otra fuente importante de desigualdad. CompanIA se lanza en España, pero la idea es llevarlo poco a poco al resto de la Unión Europea. Los modelos de voz funcionan mucho mejor en los idiomas de los que tienen más horas de datos [6], así que un hablante de castellano o de inglés estaría mejor atendido que uno de euskera, gallego, maltés o lituano. Lo mismo pasa con los mayores migrantes que hablan castellano con acento, o que en momentos de estrés vuelven a su lengua materna. Si no lo controlamos, la calidad del cuidado dependería del idioma que hable cada persona.

También hay riesgo de estigmatización. El robot aprende la rutina de cada persona para detectar cambios, pero ayunar en Ramadán, salir de noche o tomarse un vino cada día podría marcarse como «anómalo» y llegar a la familia. Se estaría tratando como un problema lo que solo es diferente, con la consiguiente pérdida de intimidad. En la misma línea está el paternalismo: si el modelo de lenguaje habla con diminutivos o da por hecho que la persona no puede hacer algo, esta se siente tratada como incapaz y acaba dejando de usar el robot. Y en la configuración de los avisos, si el sistema propone por defecto a la hija como contacto principal, estaría repitiendo un reparto de cuidados que ya recae casi siempre sobre las mujeres de la familia.

Por último, hay un sesgo que nace precisamente de cumplir la ley. Es muy difícil obtener datos de personas con deterioro cognitivo con un consentimiento válido, así que la mayoría de nuestros datos serán de mayores sanos y el robot funcionará peor con quien empieza a tener deterioro. Aunque no nos dirigimos a casos graves, un usuario puede empeorar mientras tiene el robot en casa, por lo que el deterioro leve se evalúa como un grupo más.

Fuentes de sesgo y qué hemos decidido

En los **datos**, faltan voces mayores o con problemas de habla, hay pocos idiomas minoritarios y las caídas son casi todas simuladas. Además, alguien tiene que decidir qué es una «rutina normal». Para corregirlo, reclutaremos voluntarios con un mínimo por grupo y por idioma a través de asociaciones de mayores y de personas con discapacidad, probaremos la detección de caídas con caídas reales o reconstruidas con fisioterapeutas, y la rutina de referencia será la de cada persona y no una genérica.

En el **modelo**, las reglas fijas también pueden discriminar. Una regla como «X horas sin moverse es una alerta» perjudica a quien duerme siestas largas, y un único umbral de confianza en la voz descarta más a menudo a quien habla con dificultad. Por eso los umbrales se ajustarán a cada persona y, cuando el robot no esté seguro de lo que ha oído, preguntará en lugar de ignorar la orden. Durante las primeras semanas, cuando todavía no conoce a la persona, solo avisará por caídas y no por cambios de rutina.

En el **producto** tenemos que reconocer una limitación. El robot se maneja sobre todo con la voz y su pantalla solo muestra estados, recordatorios e instrucciones breves, así que una persona sorda, con afasia o con disartria grave no puede usarlo con normalidad. En esta primera versión, por tanto, el robot discrimina en parte a estas personas. Lo que sí garantizamos es lo básico de seguridad: la detección de caídas no depende de la voz y el botón físico permite pedir ayuda o parar el robot. Más adelante queremos que todo se pueda hacer desde la pantalla con texto y pictogramas, y estudiar el reconocimiento de lengua de signos. Mientras tanto, lo

indicaremos claramente antes de la contratación para que nadie descubra la limitación cuando ya tiene el robot en casa.

Otras decisiones de producto van en la misma línea. El alta se podrá hacer en persona o por teléfono, para no excluir a quien no usa el móvil. La privacidad vendrá al máximo por defecto, porque lo que viene activado es lo que acaba teniendo la mayoría. Cualquier queja se podrá presentar hablando con el propio robot o por teléfono con una persona, no solo por internet. Y todas las funciones de seguridad irán incluidas en el plan básico, para no crear un cuidado de dos niveles según lo que cada uno pueda pagar.

En el **enfoque general y el equipo**, al dar tanta prioridad a la seguridad es fácil acabar vigilando de más. Por eso no solo medimos si el robot detecta riesgos, sino también cuántas falsas alarmas genera y si trata a las personas con condescendencia. Además, un equipo de desarrollo formado sobre todo por perfiles técnicos no conoce de primera mano lo que viven los usuarios, así que contaremos con personas mayores y con un panel de asociaciones durante las pruebas, como recomienda la OMS [1].

Una vez lanzado el robot, seguiremos midiendo los resultados por grupos con los datos de la valoración inicial. El usuario podrá decir «esto es normal para mí» para que el robot deje de avisar por un hábito concreto, y si alguna función baja del mínimo en un grupo se desactivará para ese grupo hasta que se corrija o se retirará el robot reembolsando el dinero en caso de que su funcionamiento no sea correcto. Cada año publicaremos un informe con estos resultados e intentaremos que estos vayan mejorando.

Compromisos de diseño

A partir de lo anterior, nos comprometemos a no lanzar ninguna función que no cumpla los mínimos de la siguiente sección de métricas en todos los grupos, y no solo en la media. Si el robot tiene dudas sobre lo que ha oído, preguntará, y una posible petición de ayuda se tratará siempre como una petición de ayuda. Los cambios de rutina no se comunicarán a la familia sin preguntar antes al usuario, salvo que haya un riesgo grave.

En cuanto al idioma, en España el robot funcionará desde el principio en castellano, catalán, gallego y euskera. La expansión al resto de Europa se hará país a país, y un idioma nuevo solo se activará cuando cumpla los mismos mínimos que el castellano. No habrá versiones «de segunda» para los idiomas con menos hablantes: si no se llega al nivel, se espera y se recogen más datos.

Además, todo lo relacionado con la seguridad podrá usarse sin la voz, la accesibilidad para personas sordas o con problemas de habla será una prioridad en

las siguientes versiones, y ni el tono del robot ni los contactos de aviso se asignarán por edad, sexo o diagnóstico, sino que se elegirán junto a la persona.

Herramientas de medición y corrección

Para comprobar los mínimos de la siguiente sección usaremos AI Fairness 360, una librería abierta de IBM que vimos en clase para medir y corregir sesgos en modelos de clasificación [10]. La aplicaremos a las partes del robot que deciden sí o no: detectar una caída, lanzar una alarma o marcar un cambio de rutina. Con ella calculamos la diferencia entre grupos en el porcentaje de caídas detectadas, que es la igualdad de oportunidades que hemos elegido [8], y también las falsas alarmas y los avisos de rutina por grupo. Para corregir, usaremos su método Reweighing al ajustar el detector de caídas, para compensar que las caídas reales de personas mayores son pocas frente a las simuladas. La librería compara un grupo «privilegiado» con otro, y nosotros tenemos muchos grupos. Por eso calcularemos las métricas en cada grupo y en las combinaciones más delicadas, como más de 85 años con disartria, y nos fijaremos en el mejor y el peor. El error del reconocimiento de voz no es una decisión de sí o no, así que lo mediremos por grupo con Fairlearn, de Microsoft [11]. La condescendencia la revisará el panel de personas mayores.

Para medir por grupos hay que saber a cuál pertenece cada persona. Por eso, antes de entregar el robot, haremos una entrevista y una valoración inicial con el usuario: edad, idioma, movilidad, dificultades del habla y posible deterioro leve. Además de para medir, esto sirve para ajustar el robot a la persona desde el primer día y para avisarle si alguna función no le va a funcionar bien. La parte sensible de estos datos será voluntaria y necesitará consentimiento expreso, que en personas con deterioro cognitivo se pedirá también al familiar o persona que le preste apoyo. Se guardará separada del resto, y su uso para medir sesgos se hará con las garantías que exige el AI Act [9]. A quien no quiera darla solo se le medirán indicadores que no la necesitan, como las falsas alarmas o los avisos marcados como «normal para mí».

Métricas y mínimos

No es posible cumplir todas las métricas de equidad a la vez [7], así que hemos elegido una para cada parte del sistema según qué error es más grave. Los mínimos son exigentes a propósito: el robot cuida de personas vulnerables y preferimos retrasar una función antes que lanzarla funcionando peor para algunos.

En la detección de caídas usamos la igualdad de oportunidades [8], es decir, que el porcentaje de caídas detectadas sea igual en todos los grupos, porque no detectar una caída es mucho peor que dar una falsa alarma. El robot deberá detectar al menos el 98 % de las caídas en cada grupo, sin más de 2 puntos de diferencia entre el mejor y el peor. Para el 2 % que pueda escaparse, el botón físico y la petición de ayuda por voz siguen funcionando como respaldo.

Las falsas alarmas también importan, porque si son muchas la familia acaba ignorando al robot. Fijamos un máximo de dos al mes por hogar, y ningún grupo podrá tener más de un 25 % de falsas alarmas que otro.

En la voz, lo más importante es que no se pierdan peticiones de ayuda: como máximo una de cada mil sin entender después de volver a preguntar, en cada grupo y en cada idioma. Para el resto de órdenes, la tasa de palabras mal reconocidas deberá estar por debajo del 5 % en todos los grupos, y la del grupo que peor vaya no podrá superar en más de un 20 % a la del que vaya mejor.

En las rutinas medimos cuántos avisos marca el usuario como «normal para mí». Ningún grupo podrá recibir más de un 10 % de avisos que otro, porque eso indicaría que se está tratando su forma de vivir como algo raro. Y en la conversación, un panel de personas mayores revisará las respuestas del robot, que no podrán ser condescendientes en más del 1 % de los casos en ningún grupo.

Ponemos un mínimo para el peor grupo y no solo una diferencia máxima, porque una diferencia pequeña se puede conseguir empeorando al grupo que va mejor, y eso no ayuda a nadie. Para que las cifras sean fiables, cada grupo tendrá al menos 100 personas en las pruebas. Por último, medir por salud u origen requiere datos sensibles, algo que el AI Act permite solo para detectar y corregir sesgos y con garantías (art. 10.5) [9]. Esos datos se recogen en las pruebas con voluntarios y en la valoración inicial de cada usuario, siempre con su consentimiento, y se guardarán separados del resto.

AI Logs

https://claude.ai/share/920a0f1f-53bd-4616-bf7b-6188a233c42a - Ideas y base del documento
https://claude.ai/share/c9eb2341-4934-446f-b119-adf19127e637 - Inclusión de AI Fairness para detectar sesgos

Referencias

[1] OMS (2022). Ageism in artificial intelligence for health. Recomendaciones de la OMS para evitar el edadismo en los sistemas de IA aplicados a la salud. https://www.who.int/publications/i/item/9789240040793

[2] Koenecke, A. et al. (2020). Racial disparities in automated speech recognition. PNAS, 117(14). Muestra que los sistemas de reconocimiento de voz cometen errores de forma desigual según el grupo de hablantes. https://doi.org/10.1073/pnas.1915768117

[3] Shekoufandeh, G. et al. (2025). Improving the Inclusivity of Dutch Speech Recognition by Fine-tuning Whisper on the JASMIN-CGN Corpus. arXiv:2502.17284. Evidencia que Whisper funciona peor con personas mayores. https://arxiv.org/abs/2502.17284

[4] Bagalà, F. et al. (2012). Evaluation of Accelerometer-Based Fall Detection Algorithms on Real-World Falls. PLoS ONE, 7(5). Compara el rendimiento de los algoritmos de detección de caídas en caídas reales frente a caídas simuladas. https://doi.org/10.1371/journal.pone.0037062

[5] Buolamwini, J. y Gebru, T. (2018). Gender Shades: Intersectional accuracy disparities in commercial gender classification. PMLR, 81, 77–91. Muestra fallos de los sistemas de visión según el tono de piel y el sexo. https://proceedings.mlr.press/v81/buolamwini18a.html

[6] Radford, A. et al. (2023). Robust Speech Recognition via Large-Scale Weak Supervision. ICML 2023. El error de Whisper en cada idioma depende de la cantidad de datos de entrenamiento disponibles. https://arxiv.org/abs/2212.04356

[7] Kleinberg, J., Mullainathan, S. y Raghavan, M. (2017). Inherent Trade-Offs in the Fair Determination of Risk Scores. ITCS 2017. Demuestra que no se pueden cumplir todas las métricas de equidad a la vez. https://arxiv.org/abs/1609.05807

[8] Hardt, M., Price, E. y Srebro, N. (2016). Equality of Opportunity in Supervised Learning. NeurIPS 2016. Propone la métrica de igualdad de oportunidades. https://arxiv.org/abs/1610.02413

[9] Reglamento (UE) 2024/1689 (AI Act), art. 10. Exige gestionar los sesgos en los datos de entrenamiento y regula el uso de datos sensibles para detectarlos y corregirlos. https://eur-lex.europa.eu/eli/reg/2024/1689/oj

[10] Bellamy, R. K. E. et al. (2018). AI Fairness 360: An Extensible Toolkit for Detecting, Understanding, and Mitigating Unwanted Algorithmic Bias. arXiv:1810.01943. Librería de métricas y algoritmos de corrección de sesgos usada para medir la equidad de los componentes de clasificación. https://arxiv.org/abs/1810.01943

[11] Weerts, H. et al. (2023). Fairlearn: Assessing and Improving Fairness of AI Systems. JMLR, 24(257). Librería para calcular cualquier métrica desagregada por grupo, usada para el error de reconocimiento de voz. https://jmlr.org/papers/v24/23-0389.html