Sprint 3 - CompanIA

Durante este Sprint nos hemos centrado en las diferentes implicaciones sociales de la IA respecto a nuestro proyecto. Para ello hemos realizado diferentes apartados, en este documento se incluye un resumen para ellos y referencias a los anexos donde se explica de forma más detallada cada punto.

Riesgos y respuesta ante fallos

En este apartado hemos identificado los principales riesgos técnicos, operativos y de interacción del robot: caídas o colisiones, fallos en la detección de caídas del usuario, malinterpretación de la voz, averías de hardware, pérdida de conexión, paternalismo o apego disfuncional, intentos de uso para administrar fármacos y estigmatización de rutinas. Cada riesgo se ha clasificado por categoría, probabilidad e impacto, y se han definido medidas de prevención en el diseño y una respuesta de contingencia una vez producido el fallo. Además, hemos agrupado las incidencias en tres niveles de severidad (ligero, moderado y crítico), con un protocolo de actuación para cada uno: desde la confirmación verbal y el modo básico local hasta el kill-switch, la alarma acústica y el aviso al cuidador o al 112. Las funciones vitales se procesan en local, para que no dependan de la conexión, y se registran los eventos relevantes para poder auditar los fallos. El detalle está en el anexo Tabla de Riesgos.

Plausibilidad, líneas rojas y emergencias

En este apartado hemos planteado la viabilidad de nuestra propuesta teniendo en cuenta las limitaciones tecnológicas actuales, como la complejidad del entorno doméstico y las dificultades para interpretar formas de habla no convencionales, optando por adoptar un enfoque centrado en la seguridad. Para garantizar un desarrollo ético y responsable, establecemos límites estrictos que protegen la privacidad y la autonomía de los usuarios, evitando cualquier forma de paternalismo o uso indebido de sus datos. Además, definimos un protocolo de actuación ante emergencias que incluye mecanismos de parada física y remota (*kill-switches*). De este modo, CompanIA busca consolidarse como un asistente robótico responsable que prioriza la seguridad física y el respeto a la dignidad de las personas vulnerables. Para más información mirar el anexo Plausibilidad, líneas rojas y emergencias.

Canal de reclamaciones, revisión humana y reparación

En este apartado hemos diseñado un canal de reclamaciones gratuito y accesible, con distintas vías de contacto para que cualquier persona afectada pueda comunicar fallos, daños, problemas de privacidad o situaciones de trato injusto, sin depender exclusivamente de la voz o del propio robot. Hemos establecido plazos orientativos de atención y resolución, diferenciando la gestión de reclamaciones de la respuesta inmediata ante emergencias. Toda reclamación contará con revisión humana y podrá escalarse a especialistas o solicitar

una segunda revisión por una persona distinta. También hemos definido medidas de reparación, como revertir decisiones incorrectas, corregir fallos, compensar los daños cuando corresponda y prevenir su repetición. CompanIA será responsable de coordinar este proceso, sin trasladar al usuario la obligación de identificar al proveedor causante del fallo y sin conceder acceso automático a sus familiares. El detalle está en el anexo Rendición de cuentas.

Usuarios y colectivos vulnerables

En este apartado nos hemos centrado en nombrar a los posibles usuarios presentes en el uso cotidiano del entorno del robot, además de identificar ciertas relaciones de poder que potencialmente pueden surgir. También hemos detallado estas relaciones de poder en colectivos vulnerables debido a que la situación sería peor debido a la interseccionalidad, donde los problemas pueden crecer de forma exponencial. Para indagar más sobre este tema tenemos el anexo Usuarios y colectivos vulnerables.

Sesgos y equidad

En este apartado hemos identificado los grupos de usuarios para los que el robot debe funcionar igual de bien (por edad, dificultades del habla, idioma o movilidad) y hemos analizado de dónde pueden venir los sesgos: datos, reglas del modelo y decisiones de diseño. A partir de ahí, hemos definido medidas para mitigarlos, hemos detectado la dependencia de la voz como principal limitación de esta versión y hemos fijado métricas por grupo con unos mínimos que cada función debe cumplir antes de lanzarse. El detalle está en el anexo Sesgos y Equidad.