Plan de Entrenamiento sin Violación de Copyright para *CompanIA*

Para entrenar los modelos de Inteligencia Artificial de CompanIA sin incurrir en infracciones de copyright ni vulnerar la privacidad de los usuarios, la estrategia se basará en tres pilares fundamentales:

Uso exclusivo de Datasets de Código Abierto y Licencias Libres (*Open Source & Permissive Datasets*)

- **La solución:** Para las capacidades base del lenguaje (LLM o modelos de voz), no utilizaremos material protegido por derechos de autor de terceros ni extraemos datos comerciales de internet mediante *web scraping* ilegal.
- **Cómo lo haremos:** Se emplearán exclusivamente conjuntos de datos públicos que cuenten con licencias abiertas o de dominio público (como licencias *Creative Commons CC0* o *MIT*). Ejemplos de esto son bases de datos de audio de voz anonimizadas de código abierto (como *Common Voice* de Mozilla) para entrenar el reconocimiento de acentos y tonos de voz de personas mayores.

Generación de Datos Sintéticos (*Synthetic Data*)

- **La solución:** Entrenar modelos para la detección de anomalías en el hogar (como una caída o un patrón de movimiento inusual) requiere una gran cantidad de datos, los cuales no pueden obtenerse espiando a usuarios reales sin romper el RGPD.
- **Cómo lo haremos:** Utilizaremos simuladores de física robótica en entornos virtuales (3D) para generar datos sintéticos. El sistema genera miles de horas de vídeos y patrones de movimiento simulados de forma artificial. Al ser datos creados por ordenador desde cero, no existe ningún problema de derechos de autor ni de violación de la privacidad de personas reales.

Privacidad y Datos Propios Anonimizados (*Federated Learning / Edge AI*)

- **La solución:** A medida que el robot esté en funcionamiento en fase de pruebas con voluntarios, evitaremos centralizar y copiar datos privados de las interacciones reales de los usuarios para entrenar los modelos centrales.
- **Cómo lo haremos:** Aplicaremos técnicas de Aprendizaje Federado (*Federated Learning*). Esto significa que el robot aprende de las interacciones locales de forma anónima, pero solo actualiza los parámetros generales del algoritmo en el servidor sin transferir datos personales ni material protegido. De esta forma, se respeta escrupulosamente tanto el copyright como el derecho a la intimidad.

AI Log

https://chatgpt.com/share/6aef65f8-3504-83ed-8c95-0da56356f47c